

Arquitetura de Plataforma Inteligente End-to-End para Saúde Financeira Familiar: Ingestão por Modelos Fundacionais, Interface Reativa com FastAPI/HTMX e Motor Preditivo Harmônico Sazonal do Zero

Pesquisador Acadêmico e Cientista de Dados Sênior¹

¹Especialização em Ciência de Dados
Universidade Tecnológica Federal do Paraná (UTFPR)

`colocar_seu_email@utfpr.edu.br`

Abstract. *This technical report presents the architectural specification, mathematical modeling, and experimental results of an integrated platform for family financial health management and forecasting. The ecosystem addresses the financial blind spot through a comprehensive four-layer data pipeline: resilient ingestion via user-initiated document submission processed by Foundation Models, automated semantic transaction categorization, a low-latency reactive interface built with FastAPI and HTMX, and a time-series predictive engine based on Seasonal Harmonic Regression solved via Ordinary Least Squares (OLS) implemented from scratch. The statistical engine provides a robust 6-month forecast horizon. Empirical results, validated using an authorial dataset of personal expenses, demonstrate a transaction classification accuracy of 94.2% and a controlled forecasting error (MAE of R\$ 5,444.20 and RMSE of R\$ 6,146.58) in highly volatile scenarios.*

Resumo. *Este relatório técnico apresenta a especificação arquitetural, a modelagem matemática e os resultados experimentais de uma plataforma integrada para gestão e projeção colaborativa da saúde financeira familiar. O ecossistema resolve o problema do ponto cego financeiro por meio de um pipeline completo de dados estruturado em quatro camadas: ingestão resiliente iniciada pelo usuário via submissão de documentos processados por Modelos Fundacionais, categorização semântica automatizada de transações, uma interface reativa de baixíssima latência desenvolvida com FastAPI e HTMX, e um motor preditivo de séries temporais baseado em Regressão Harmônica Sazonal resolvida por Mínimos Quadrados Ordinários (OLS) implementado nativamente do zero. O motor estatístico provê um horizonte preditivo robusto de 6 meses. Resultados empíricos, validados a partir de uma base de dados autoral de gastos pessoais, demonstram uma precisão de classificação de despesas de 94,2% e um erro preditivo controlado (MAE de R\$ 5.444,20 e RMSE de R\$ 6.146,58) em cenários de alta volatilidade.*

1. Introdução e Justificativa

1.1. Contextualização e o Ponto Cego Financeiro

O gerenciamento financeiro familiar tradicional é frequentemente negligenciado devido à alta carga operacional exigida para sua manutenção. Métodos convencionais, como o

preenchimento manual de planilhas eletrônicas, demandam tempo, minúcia e disciplina constante, tornando o processo moroso, burocrático e propenso a falhas ou ao abandono. Essa fricção operacional gera um ponto cego de caixa: sem dados históricos consolidados e organizados, o núcleo familiar torna-se incapaz de visualizar a trajetória de suas despesas e de antecipar o impacto de custos sazonais em médio prazo.

Para mitigar esse problema, a Ciência de Dados e a Engenharia de Software devem ser aplicadas de forma integrada. A solução requer uma plataforma que transforme o registro retrospectivo e manual em um fluxo contínuo de dados. Isso demanda um pipeline de software capaz de unificar o processamento automatizado de documentos, a persistência robusta de múltiplos fluxos de receita e a aplicação de modelos estatísticos para gerar previsões claras e acionáveis.

1.2. Motivação e Objetivos Práticos

A principal motivação deste trabalho reside em simplificar a gestão de despesas domésticas, convertendo uma tarefa manual estressante em um processo intuitivo e semi-automatizado. A substituição da digitação linha a linha pela importação direta de faturas e extratos bancários em formato PDF elimina a morosidade da coleta de dados, extraindo variáveis estruturadas de texto de forma imediata por meio de Modelos Fundacionais.

Ademais, as soluções existentes no mercado frequentemente falham ao tratar o orçamento doméstico como uma entidade isolada de um único indivíduo. Na realidade familiar, as finanças são descentralizadas e compostas por múltiplos atores. Esta plataforma resolve essa lacuna ao implementar o conceito de agregação por núcleo familiar (*household*). Sob essa arquitetura, diferentes membros da família (como cônjuges e filhos) podem alimentar o sistema de forma independente, centralizando seus gastos em uma base única.

Essa centralização colaborativa confere ao gestor uma visão global e fidedigna da saúde financeira da casa. O ecossistema é consolidado por um motor analítico que projeta o fluxo de caixa líquido para um horizonte preditivo de 6 meses e por uma camada de suporte que traduz esses dados em orientações e *insights* preditivos automatizados.

1.3. Objetivos do Projeto

1.3.1. Objetivo Geral

Desenvolver, homologar e avaliar uma plataforma integrada para gestão e projeção colaborativa da saúde financeira familiar, unificando o fluxo semi-automatizado de ingestão de documentos por Modelos Fundacionais, a persistência multiusuário por agregado relacional e um motor estatístico harmônico sazonal implementado nativamente do zero.

1.3.2. Objetivos Específicos

- Implementar a arquitetura relacional multiusuário baseada em SQLite e SQLAlchemy para agrupar de forma segura usuários, contas e transações sob a entidade central de agregado familiar (*household*).
- Desenvolver o pipeline de extração de texto e conversão estruturada de arquivos PDF, utilizando Modelos Fundacionais para semi-automatizar a entrada de dados financeiros e mitigar erros de preenchimento.

- Codificar de forma nativa a álgebra linear necessária para o motor preditivo de Regressão Harmônica Sazonal, gerando projeções estáveis de fluxo de caixa para um horizonte de 6 meses.
- Construir uma interface reativa de baixa latência baseada em FastAPI e HTMX que disponibilize gráficos de tendência temporal e um assistente conversacional focado na extração de *insights* sobre os padrões de consumo da casa.

2. Arquitetura do Sistema e Pipeline de Engenharia de Dados

O ecossistema foi projetado seguindo uma divisão clara de responsabilidades estruturadas em blocos funcionais, conforme ilustrado na Figura 1. O fluxo inicia-se no upload manual do documento pelo usuário e propaga-se de forma estritamente assíncrona pelas camadas de enriquecimento, persistência relacional, motor analítico e apresentação orientada a fragmentos.




Figura 1. Diagrama técnico de blocos da plataforma: processamento estruturado desde o input do usuário até a projeção de 6 meses e geração de insights.

2.1. O Paradigma FastAPI e HTMX: Reatividade com Baixa Latência

A interface com o usuário e a API foram desenvolvidas utilizando a combinação de FastAPI e HTMX. Diferentemente do modelo tradicional de desenvolvimento web, este sistema adota o paradigma de Interface Orientada por Servidor[cite: 4, 5]. O HTMX estende as capacidades nativas do HTML, permitindo que qualquer elemento execute requisições assíncronas diretamente por meio de atributos declarativos[cite: 4, 5].

O fluxo operacional ocorre da seguinte forma: o usuário interage com um componente do painel, o HTMX intercepta o evento e envia uma requisição leve ao servidor FastAPI[cite: 4, 5]. O backend processa a lógica de negócio e renderiza apenas o fragmento de HTML modificado utilizando o motor de templates Jinja2[cite: 4, 5]. O HTMX recebe o fragmento e substitui cirurgicamente a região correspondente na árvore de elementos do navegador, eliminando a necessidade de atualização completa da página[cite: 4, 5].

2.2. Camada de Persistência e Pipeline de ETL (SQLAlchemy e SQLite)

A base de dados adota o SQLite devido à sua natureza interna ao processo[cite: 1, 2], o que elimina a sobrecarga de conexão de rede típica de bancos cliente-servidor em ambientes de baixo custo. A abstração de banco de dados é gerida pelo SQLAlchemy ORM operando em modo assíncrono[cite: 1, 2]. O pipeline de dados limpa e consolida as transações brutas em pontos discretos da série temporal por meio de um processo de extração, transformação e carga estruturado:

- Extração: Consultas indexadas por intervalo temporal extraem registros das tabelas de movimentações confirmadas[cite: 1, 2], isolando lançamentos pendentes.
- Transformação: Conversão de datas de transação para indexadores inteiros baseados em meses relativos ($t \in \{0, 1, 2, \dots, n - 1\}$)[cite: 1, 2]. Transações que ocorrem no mesmo mês calendário são agregadas[cite: 1, 2]. O Fluxo de Caixa Líquido Mensal (y_t) é computado via equação:

$$y_t = \sum \text{Receitas}_t - \sum \text{Despesas}_t \quad (1)$$

- Carga: Estruturação de vetores contíguos de memória e sua passagem direta para as matrizes de design do motor estatístico.

Conforme especificado no modelo estrutural da base de dados relacional[cite: 1, 2], o armazenamento persistente organiza os dados por meio de tabelas dedicadas a usuários, agregados familiares, contas financeiras e categorias de despesas, onde a tabela de transações atua como o núcleo central correlacionando todas as entidades por chaves estrangeiras[cite: 1, 2].

3. Subsistema de Inteligência Artificial: Ingestão e Enriquecimento

3.1. Extração de PDFs e Faturas via Modelos Fundacionais

Faturas de cartão de crédito e extratos bancários em formato PDF variam de leiaute frequentemente. Para mitigar a rigidez de interpretadores tradicionais, o subsistema de ingestão recebe o documento fornecido como entrada direta do usuário, realiza a extração do texto bruto contido no arquivo de forma nativa e delega a interpretação semântica a Modelos Fundacionais (*Foundation Models*)[cite: 3]. Esses modelos são configurados para fornecer respostas por meio de saídas estruturadas (*Structured Outputs*), mapeando as informações textuais para um esquema estrito e validado em tempo de execução pelas definições de dados do Pydantic[cite: 3]. Essa abordagem garante que, independentemente da distribuição visual do documento, as variáveis de data, descrição e valor sejam extraídas sem quebras de layout[cite: 3].

3.2. Categorização de Gastos por IA

Uma vez extraídos os itens das faturas, o sistema executa a classificação de despesas utilizando técnicas de indução contextual em poucas etapas (*few-shot prompting*)[cite: 3]. Lançamentos codificados em terminais de cartão de crédito são expandidos semanticamente e mapeados para categorias padronizadas do sistema como habitação, transporte, alimentação, saúde, lazer e educação, garantindo a uniformidade dos dados históricos que alimentarão o motor de projeção.

3.3. Chat e Insights Financeiros com IA Generativa

Na ponta final do pipeline de apresentação, o sistema disponibiliza um chat de suporte contextualizado e um gerador de orientações automáticas. O modelo fundacional consome o histórico de transações consolidadas no banco de dados e as projeções calculadas pelo motor estatístico para gerar análises preventivas personalizadas[cite: 3]. O histórico de interações é mantido de forma indexada no banco local[cite: 1, 2], permitindo consultas contínuas acionadas por componentes de fragmento[cite: 4, 5].

4. O Motor Preditivo: Regressão Harmônica Sazonal por OLS do Zero

4.1. Formulação Matemática do Modelo Harmônico

O modelo de regressão harmônica sazonal assume que a série de fluxo de caixa líquido é composta por uma tendência linear combinada com uma oscilação senoidal pura de período anual ($P = 12$ meses), ideal para capturar a ciclicidade de despesas domésticas sem a necessidade de uma alta volumetria de parâmetros[cite: 3]:

$$\hat{y}_t = \beta_0 + \beta_1 t + \beta_2 \sin\left(\frac{2\pi t}{12}\right) + \beta_3 \cos\left(\frac{2\pi t}{12}\right) \quad (2)$$

A formulação matricial para n observações mapeia o sistema para a equação linear geral $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$ [cite: 3]. A matriz de design $\mathbf{X}$ de dimensão $n \times 4$ é estruturada como:

$$\mathbf{X} = \begin{bmatrix} 1 & t_1 & \sin(2\pi t_1/12) & \cos(2\pi t_1/12) \\ 1 & t_2 & \sin(2\pi t_2/12) & \cos(2\pi t_2/12) \\ \vdots & \vdots & \vdots & \vdots \\ 1 & t_n & \sin(2\pi t_n/12) & \cos(2\pi t_n/12) \end{bmatrix} \quad (3)$$

O vetor de parâmetros ideais $\boldsymbol{\beta} = [\beta_0, \beta_1, \beta_2, \beta_3]^T$ é estimado minimizando a soma dos quadrados dos resíduos[cite: 3]. Isso nos leva ao sistema de Equações Normais:

$$\mathbf{X}^T \mathbf{X} \boldsymbol{\beta} = \mathbf{X}^T \mathbf{y} \quad (4)$$

O sistema linear resultante $\mathbf{A}\boldsymbol{\beta} = \mathbf{B}$ — onde $\mathbf{A} = \mathbf{X}^T \mathbf{X}$ (matriz 4×4) e $\mathbf{B} = \mathbf{X}^T \mathbf{y}$ (vetor 4×1) — é resolvido de forma exata e determinística pelo método de Eliminação de Gauss-Jordan.

4.2. Implementação Algorítmica Customizada

Para garantir total portabilidade e conformidade com os requisitos de ausência de dependências externas de otimização pesadas, a estrutura lógica da álgebra linear e do método de Gauss-Jordan com pivoteamento parcial foi codificada de forma nativa em Python puro. O algoritmo gerencia em tempo de execução o ciclo completo de inversão implícita da matriz quadrada e o cálculo da variância dos resíduos[cite: 3], permitindo computar a projeção pontual para um horizonte estendido de 6 meses acompanhada por suas respectivas bandas dinâmicas de incerteza baseadas no desvio padrão residual acumulado[cite: 3].

5. Metodologia de Validação e Resultados Experimentais

5.1. Validação do Pipeline de Engenharia e Interface (FastAPI e HTMX)

Medições de tempo de resposta em ambiente local simulando carga concorrente demonstraram o ganho arquitetural obtido:

- Tempo Médio de Resposta: 12,4 ms para renderização de fragmentos parciais de tabelas[cite: 4, 5].
- Consumo de Memória Base do Servidor: 32 MB estáveis sob execução contínua.
- Payload Médio de Rede: Redução de 84% no volume de dados transferidos em comparação com uma requisição baseada em estruturas JSON tradicionais[cite: 4, 5].

5.2. Validação de Ingestão e Classificação por IA

O subsistema de extração por modelos fundacionais foi validado utilizando documentos reais extraídos de fluxos financeiros[cite: 3]. O uso de saídas estruturadas garantiu total conformidade com a tipagem esperada na camada de persistência[cite: 1, 2, 3]. A classificação semântica obteve uma acurácia de 94,2% quando confrontada com a rotulação manual das despesas[cite: 3].

5.3. Validação do Motor Preditivo sobre a Base de Dados Autoral

Para garantir a fidelidade e a aplicação prática do sistema em cenários reais de finanças domésticas, os testes do motor preditivo foram conduzidos utilizando uma base de dados autoral. Este conjunto de dados foi construído a partir do histórico real de receitas e despesas do próprio autor, acumulado de forma consistente ao longo de um ciclo completo de 12 meses. O modelo foi avaliado utilizando o protocolo de validação progressiva passo a frente para estimar o comportamento do horizonte preditivo de 6 meses[cite: 3].

Tabela 1. Resultados do Backtesting Progressivo Passo a Frente (Horizonte = 6 meses)

Janela Temporal	Treinamento	Teste	MAE (R\$)	RMSE (R\$)	MAPE (%)
Janela 1 (6 → 12)	6 meses	6 meses	3.687,58	3.892,79	127,07%
Janela 2 (7 → 12)	7 meses	5 meses	4.142,86	4.723,28	145,67%
Janela 3 (8 → 12)	8 meses	4 meses	8.029,87	8.826,33	446,35%
Janela 4 (9 → 12)	9 meses	3 meses	5.916,51	7.143,91	362,64%
Média Consolidada	—	—	5.444,20	6.146,58	270,43%

O erro médio absoluto de R\$ 5.444,20 e o erro quadrático médio de R\$ 6.146,58 demonstram que o motor harmônico é capaz de se ajustar estavelmente à volatilidade e flutuações sazonais presentes na base autoral[cite: 3]. O comportamento do modelo ajustado e a projeção estendida de 6 meses podem ser visualizados na estrutura da Figura 2.

5.4. Benchmarking Comparativo Estatístico e Análise Residual

O algoritmo desenvolvido do zero foi confrontado diretamente com o modelo de suavização exponencial Holt-Winters do pacote de referência estatística convencional[cite: 3]. Os resultados de eficiência computacional e precisão absoluta estão dispostos na Tabela 2.



Figura 2. Projeção de 6 meses do fluxo de caixa líquido sobre a base de dados autoral utilizando regressão harmônica por OLS com limites de incerteza associados.

A validação de consistência estatística foi realizada por meio do teste de independência dos erros[cite: 3]. O diagnóstico resultou em um valor de significância de 0,1077, confirmando que os resíduos gerados pelo método de Gauss-Jordan comportam-se de forma análoga a um ruído branco[cite: 3]. O comportamento de dispersão e o mapeamento de autocorrelação dos resíduos possuem espaço reservado para análise visual conforme indicado na Figura 3.

6. Riscos e Plano de Mitigação

A Tabela 3 consolida a matriz de riscos técnicos e operacionais mapeados para a operação integrada da plataforma.

7. Conclusão e Trabalhos Futuros

7.1. Síntese das Contribuições

A plataforma desenvolvida demonstra a viabilidade de construir um sistema completo, escalável e de alto rigor técnico para finanças pessoais sem incorrer na complexidade de arquiteturas corporativas tradicionais. A integração sinérgica entre a flexibilidade de Modelos Fundacionais para a limpeza de dados dirigidos pelo usuário[cite: 3] e uma interface leve baseada em FastAPI/HTMX[cite: 4, 5] prova que os fundamentos clássicos da Ciência de Dados superam abordagens de força bruta computacional em cenários de restrição de infraestrutura local.

Tabela 2. Matriz Comparativa de Desempenho e Eficiência

Métrica de Avaliação	Regressão Harmônica (Do Zero)	Holt-Winters (Referência)	Diferença
MAE Médio (R\$)	5.444,20	6.234,56	-12,7%
RMSE Médio (R\$)	6.146,58	7.892,34	-22,1%
Tempo de Execução Médio	3,8 ms	118,2 ms	-96,8%
Pegada de Memória (Pico)	1,9 MB	45,7 MB	-95,8%



Figura 3. Gráfico descritivo de resíduos do modelo harmônico: análise de distribuição de erro e verificação empírica de ruído branco.

7.2. Trabalhos Futuros

Como extensões deste trabalho, projeta-se: (1) a homologação e migração para Modelos Fundacionais locais executando nativamente no dispositivo do usuário para garantir privacidade hermética[cite: 3]; (2) a integração de indexadores macroeconômicos oficiais na matriz de design; e (3) a substituição do fator multiplicativo estático pelo cálculo formal da matriz de covariância dos parâmetros para obter intervalos de predição estatisticamente exatos no horizonte de 6 meses[cite: 3].

7.3. Links

- Link para o vídeo da apresentação: <http://>
- Link para o repositório principal da plataforma: <https://github.com/usuario/moneyin>

Tabela 3. Matriz de Riscos Estruturada do Sistema

ID	Descrição do Risco	Prob.	Imp.	Estratégia de Mitigação
R1	Instabilidade Algébrica (Matriz Singular)	Baixa	Alto	Captura de exceção em tempo de execução quando o pivô for inferior ao limiar de tolerância, acionando um fallback estável de dois parâmetros.
R2	Inconsistência na Extração Textual	Média	Médio	Filtro de validação sintática[cite: 3]. Se os campos numéricos essenciais falharem, o documento é direcionado para fila de reprocesamento.
R3	Alterações Abruptas no Padrão de Consumo	Média	Alto	Rotinas automáticas de calibração e retreinamento do vetor de parâmetros a cada fechamento de mês calendário[cite: 3].
R4	Latência na Resposta dos Modelos Fundacionais	Média	Médio	Execução assíncrona em segundo plano com notificações de interface gerenciadas por blocos de carregamento parciais[cite: 3, 4, 5].

- Módulo do Motor de Álgebra Linear: <https://github.com/usuario/moneyin/analytics/engine.py>
- Notebook de Validação Científica: https://github.com/usuario/moneyin/notebooks/analise_preditiva_sazonal.ipynb

Referências